ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÁO CÁO BÀI TẬP LỚN

NHÓM 3

MÔN: KHAI PHÁ DỮ LIỆU

PHÂN TÍCH HÀNH VI NGƯỜI CHƠI PUBG, PHÂN CỤM VÀ HỒI QUY KẾT QUẢ SAU TRẬN

Giảng viên hướng dẫn: ThS. Phạm Kim Thành

Thành viên thực hiện:

24100093 - Kiều Thị Thu Trang - 24100093@st.phenikaa-uni.edu.vn

24100012 - Trần Minh Sang - 24100012@st.phenikaa-uni.edu.vn

24102651 - Ngô Quang Thiện - 24102651@st.phenikaa-uni.edu.vn

Mã nguồn dự án: `https://github.com/thyelmot/Project_PUBG`

Hà Nội, tháng 10 năm 2026

TÓM TẮT

Đề tài phân tích 67.369.231 bản ghi người chơi–trận đấu và 65.370.475 sự kiện đầu vào từ bộ dữ liệu PUBG phiên bản 3. Nhóm kết hợp thống kê và tương quan, phân cụm KMeans riêng theo chế độ, cùng hồi quy tuyến tính trên hai biến mục tiêu. Dữ liệu được chia theo nhóm trận với tỷ lệ xấp xỉ 70/15/15; quá trình tính toán giữ toàn bộ cohort hợp lệ của từng bài toán.

Trên 10.085.842 dòng test của bài toán thứ hạng, mô hình có timing đạt MAE 0,173516, RMSE 0,217318 và $R^2 = 0,481642$. So với cùng mô hình không có timing, MAE giảm khoảng 7,11%. Kết quả phân cụm có 2 cụm Solo, 4 cụm Duo và 3 cụm Squad, nhưng các cụm Duo/Squad mất cân đối và độ ổn định theo seed cần được xem xét. Mô hình thời gian sống có sai số rất lớn và chưa đạt yêu cầu sử dụng. Báo cáo phân tích rõ các giới hạn về ngoại lệ, đơn vị thời gian giả định, thông tin hậu trận và việc chưa có khoảng tin cậy. Số liệu được đối chiếu trực tiếp với CSV và manifest đầy đủ của lần chạy đã lưu.

MỤC LỤC

1 GIỚI THIỆU BÀI TOÁN **1**

1.1 Đặt vấn đề 1

1.2 Đầu vào và đầu ra của bài toán 1

1.3 Ý nghĩa và câu hỏi nghiên cứu 1

1.4 Các hướng tiếp cận và giải pháp đề xuất 2

2 XÂY DỰNG TẬP DỮ LIỆU **3**

2.1 Giới thiệu bộ dữ liệu 3

2.2 Đơn vị quan sát và biến mục tiêu 3

2.3 Kiểm tra chất lượng và bảo toàn dữ liệu 4

2.4 Khám phá phân phối và giá trị thiếu 4

2.5 Chia tập và chống rò rỉ dữ liệu 6

2.6 Xây dựng Combat Timing 7

2.7 Đặc trưng và quyền sử dụng theo mục tiêu 8

3 CÁC PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU **10**

3.1 Tương quan Pearson và Spearman 10

3.2 Phân cụm KMeans theo chế độ chơi 10

3.3 Mô hình cơ sở và hồi quy tuyến tính 11

3.4 Thước đo đánh giá 11

4 THỬ NGHIỆM VÀ KẾT QUẢ **12**

4.1 Thiết lập và nguồn bằng chứng 12

4.2 RQ1: Quan hệ giữa hành vi và kết quả 12

4.3 RQ2: Phân nhóm hành vi 14

4.4 RQ3: Kết quả hồi quy trên validation 18

4.5 Kết quả đầy đủ trên tập test 19

4.6 Đóng góp của Combat Timing trên test 20

4.7 Phân tích sai số 21

4.8 Hệ số mô hình và khả năng diễn giải 23

5 THẢO LUẬN KẾT QUẢ **25**

5.1 Vai trò của chất lượng dữ liệu 25

5.2 Giá trị và giới hạn của phân cụm 25

5.3 Diễn giải hiệu năng hồi quy 25

5.4 Hạn chế và hướng phát triển 26

6 TỔ CHỨC HỆ THỐNG VÀ KHẢ NĂNG TÁI LẬP **27**

6.1 Quy trình thực thi S01–S12 27

6.2 Xử lý dữ liệu vượt bộ nhớ 27

6.3 Bàn giao và truy vết 27

7 KẾT LUẬN **28**

A NGUỒN BẰNG CHỨNG VÀ PHẠM VI BẢNG TRÍCH **30**

1 GIỚI THIỆU BÀI TOÁN

1.1 Đặt vấn đề

Trong các trò chơi sinh tồn nhiều người tham gia, kết quả cuối cùng được hình thành từ hàng loạt quyết định: lựa chọn giao tranh, di chuyển, sử dụng phương tiện và hỗ trợ đồng đội. PUBG cung cấp một bối cảnh phù hợp để nghiên cứu những quyết định này thông qua dữ liệu trận đấu. Tuy nhiên, một bảng xếp hạng chỉ phản ánh kết quả cuối cùng; để hiểu hành vi phía sau kết quả, cần kết hợp thống kê người chơi với diễn biến sự kiện trong trận.

Bài toán đặt ra cho nhóm là: từ dữ liệu sau trận, có thể nhận diện những mối liên hệ hành vi nào, hình thành các nhóm người chơi ra sao, và giải thích được bao nhiêu biến thiên của thời gian sống sót hoặc thứ hạng? Đây là bài toán khai phá dữ liệu có cả thành phần mô tả và thành phần hồi quy. Đầu ra được sử dụng để phân tích hồi cứu; các biến tổng kết sau trận chưa sẵn có tại thời điểm bắt đầu trận đấu.

Thứ nhất, dữ liệu có quy mô hàng chục triệu dòng và được chia thành nhiều tệp. Việc ghép sự kiện với thống kê người chơi phải bảo toàn số dòng và tránh nhân bản quan sát. Thứ hai, đơn vị, giá trị thiếu và ngoại lệ có thể ảnh hưởng trực tiếp đến kết luận. Thứ ba, dữ liệu có cấu trúc nhóm: nhiều người chơi cùng trận và nhiều đồng đội cùng thứ hạng. Nếu bỏ qua cấu trúc này, phép đánh giá có thể tạo ra cảm giác chính xác hơn thực tế.

1.2 Đầu vào và đầu ra của bài toán

Đầu vào gồm hai nhóm dữ liệu: bảng tổng hợp theo người chơi trong từng trận và bảng sự kiện hạ gục. Các biến hành vi chính bao gồm số lần hạ gục, sát thương, quãng đường đi bộ, quãng đường di chuyển bằng phương tiện, hỗ trợ và trạng thái hạ gục đối thủ. Thông tin thời điểm giao tranh được bổ sung từ bảng sự kiện.

Đầu ra gồm ba nhóm: bảng thống kê và quan hệ hành vi; nhãn cụm cùng mô tả hành vi cho từng chế độ Solo, Duo, Squad; kết quả hồi quy và phân tích sai số trên hai mục tiêu. Toàn bộ kết quả được lưu cùng thông tin cấu hình, nguồn và các bước thực thi.

1.3 Ý nghĩa và câu hỏi nghiên cứu

Về học thuật, đề tài vận dụng quy trình khám phá tri thức, thống kê, tiền xử lý, hồi quy và phân cụm trong một bài toán thống nhất. Về thực hành, đề tài giúp nhóm hiểu rằng chất lượng của một mô hình phụ thuộc vào cách xác định đơn vị quan sát, thiết kế đặc trưng và kiểm soát chất lượng dữ liệu.

- RQ1: Hành vi nào có liên hệ với thời gian sống sót và thứ hạng?

- RQ2: Có thể hình thành những nhóm hành vi nào khi phân cụm riêng từng chế độ chơi?
- RQ3: Các đặc trưng sau trận giải thích kết quả đến mức nào; thông tin thời điểm giao tranh đóng góp thêm bao nhiêu?

1.4 Các hướng tiếp cận và giải pháp đề xuất

Thống kê mô tả giúp nhận biết phân phối và ngoại lệ nhưng chưa tạo thành nhóm hành vi. Phân cụm KMeans bổ sung góc nhìn về sự tương đồng giữa người chơi, song nhạy với thang đo và giá trị cực đoan. Hồi quy tuyến tính cho phép so sánh với mô hình cơ sở và diễn giải hệ số, nhưng không bảo đảm mô tả tốt mọi quan hệ phi tuyến. Vì vậy, nhóm kết hợp ba hướng tiếp cận thay vì coi một thuật toán là lời giải cho mọi câu hỏi.

Quy trình đề xuất gồm kiểm nguồn, làm sạch và chia tập; tạo đặc trưng; khám phá quan hệ; phân cụm; hồi quy; đánh giá và đóng gói báo cáo. Hai mô hình dự đoán hằng số bằng trung bình và trung vị tập huấn luyện được sử dụng làm mốc so sánh. Nhóm giữ nguyên toàn bộ dữ liệu hợp lệ theo từng bài toán và tổ chức tính toán theo khối để đáp ứng giới hạn bộ nhớ.

2 XÂY DỰNG TẬP DỮ LIỆU

2.1 Giới thiệu bộ dữ liệu

Nguồn nghiên cứu là PUBG Match Deaths and Statistics, phiên bản 3, của tác giả Kaggle `skihikingkevin`. Thông tin giấy phép trong cấu hình chạy là CC0: Public Domain. Kiểm kê thực thi ghi nhận 5 tệp aggregate và 5 tệp sự kiện. Tổng số dòng lần lượt là 67.369.231 và 65.370.475. Đây là số bản ghi, không phải số người chơi duy nhất.

Bảng 1: Kiểm kê toàn bộ tệp nguồn

Nhóm	Tệp	Số dòng
aggregate	aggregate/agg_match_stats_0.csv	13849287
aggregate	aggregate/agg_match_stats_1.csv	13844275
aggregate	aggregate/agg_match_stats_2.csv	13841504
aggregate	aggregate/agg_match_stats_3.csv	13840680
aggregate	aggregate/agg_match_stats_4.csv	11993485
event	deaths/kill_match_stats_final_0.csv	13426348
event	deaths/kill_match_stats_final_1.csv	13440889
event	deaths/kill_match_stats_final_2.csv	13431052
event	deaths/kill_match_stats_final_3.csv	13431331
event	deaths/kill_match_stats_final_4.csv	11640855

Nguồn: `source_inventory.csv`, số liệu đầy đủ đã lưu.

2.2 Đơn vị quan sát và biến mục tiêu

Phân tích quan hệ và hồi quy sử dụng đơn vị người chơi–trận đấu. Phân cụm sử dụng hồ sơ người chơi–chế độ, được tổng hợp qua nhiều trận. Một người có thể xuất hiện trong nhiều hồ sơ nếu tham gia nhiều chế độ; tên hiển thị chưa phải bằng chứng về định danh tài khoản bất biến.

Mục tiêu thứ nhất là `player_survive_time`, yêu cầu hữu hạn và không âm. Đơn vị giây đang được sử dụng theo giả định đã phê duyệt; nguồn chạy ghi rõ `assumed_seconds`, chưa phải đơn vị đã được tác giả xác minh. Mục tiêu thứ hai là thứ hạng đội chuẩn hóa:

$$y_{\text{placement}} = 1 - \frac{r-1}{N_{\text{teams}}-1}.$$

Trong đó r là thứ hạng đội và N_{teams} là số đội hợp lệ trong trận trước khi lọc theo mục tiêu. Giá trị gần 1 biểu thị thứ hạng tốt hơn. Các trận không đủ điều kiện xác định mẫu số hoặc có thứ hạng mâu thuẫn được xử lý bằng cờ hợp lệ của riêng mục tiêu đó.

2.3 Kiểm tra chất lượng và bảo toàn dữ liệu

Sổ đối soát ghi nhận 67.369.231 dòng trước và sau ba bước kiểm tra: trùng lặp chính xác, xung đột định danh và thiếu mã trận hoặc giá trị số không hợp lệ. Số dòng bị loại ở các bước này bằng 0. Kết quả đó chỉ xác nhận các quy tắc đã kiểm không loại dòng; nó không có nghĩa dữ liệu hoàn toàn không có ngoại lệ hoặc không có vấn đề về ngữ nghĩa.

Sau khử trùng sự kiện, số bản ghi còn 65.370.264, giảm 211 dòng. Có 59.883.734 sự kiện đủ điều kiện timing tuyệt đối và 59.560.628 đủ điều kiện timing theo pha. Sau ghép, số dòng người chơi vẫn là 67.369.231. Phép đối soát này giúp phát hiện ghép nhiều–nhiều ngoài ý muốn.

Bảng `feature_validation.csv` cho biết 67.239.102 dòng có placement hợp lệ, ít hơn tổng số dòng 130.129 dòng, tương đương khoảng 0,193%. Đây là thiếu hợp lệ theo mục tiêu, không phải số dòng bị xóa khỏi toàn bộ dự án. Một dòng vẫn có thể tham gia bài toán survival dù không đủ điều kiện cho placement. Trên toàn bộ dữ liệu, các tỷ số cũng có số lượng hợp lệ riêng: damage_per_kill có 28.249.181 giá trị và assist_ratio có 32.411.373 giá trị.

2.4 Khám phá phân phối và giá trị thiếu

Bảng 2: EDA train+validation, N = 57.262.855

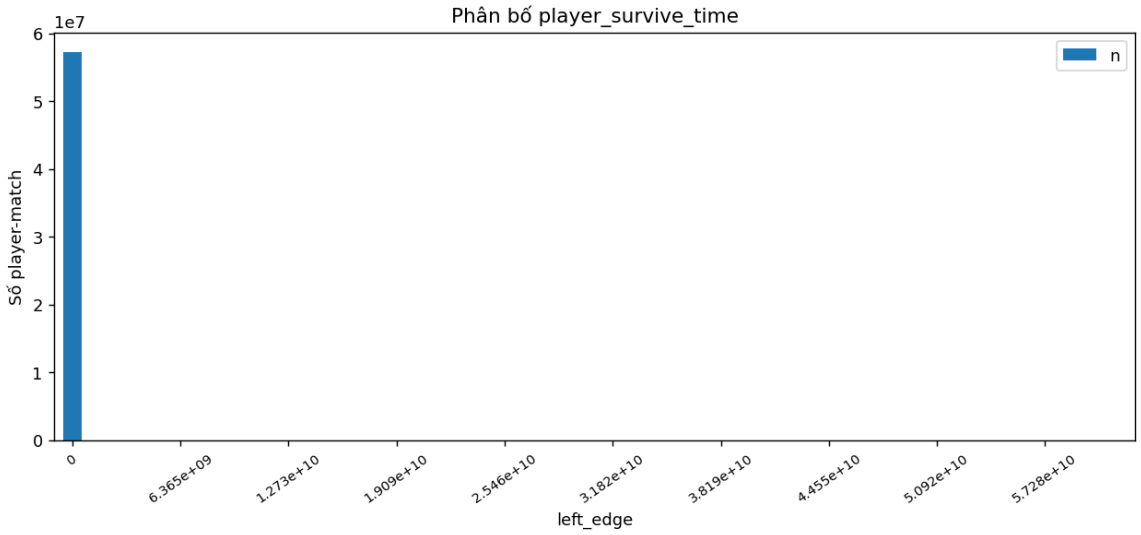
Biến	Trung bình	Trung vị	Lớn nhất	Thiếu
player_kills	0.887266	0	94	0
player_dmg	123.948	77	9408	0
player_dist_walk	1284.17	848.921	1.27365e+06	0
player_dist_ride	1156.07	0	506175	0
first_kill_time	516.182	312	2304	33354079
player_survive_time	50803.8	653.354	6.36482e+10	0
normalized_placement	0.494023	0.487805	1	109595

Nguồn: `eda_statistics.csv`, số liệu đầy đủ đã lưu.

Trung vị số lần hạ gục bằng 0, trong khi trung bình xấp xỉ 0,887. Trung vị quãng đường đi xe bằng 0 cho thấy không thể mặc định mọi người chơi đều sử dụng phương tiện. Các tỷ số cần được diễn giải theo mẫu số: sát thương trên mỗi lần hạ gục không xác định khi số lần hạ gục bằng 0. Gán tất cả những trường hợp này thành 0 sẽ làm thay đổi ý nghĩa biến.

Đặc biệt, thời gian sống có trung vị 653,354 nhưng trung bình 50.803,765 và giá trị lớn nhất khoảng $6,365 \times 10^{10}$ trong bảng EDA. Khoảng cách rất lớn giữa trung bình và trung vị là bằng chứng cần điều tra giá trị cực đoan. Bảng này chưa đủ để kết luận nguyên nhân là đơn vị, lỗi nguồn hay lỗi xử lý. Nhóm giữ kết quả hiện có và công bố giới hạn thay vì tự loại ngoại lệ sau khi xem hiệu năng.

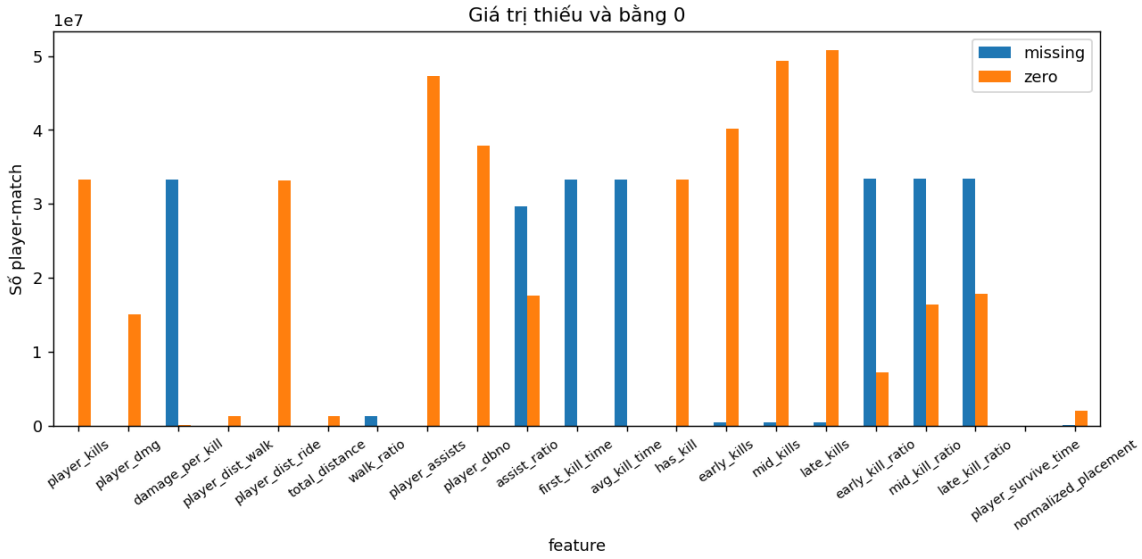
Phạm vi EDA ở đây là train+validation, gồm 57.262.855 dòng, không phải toàn bộ 67.369.231 dòng đầu vào. Trung vị survival tương đương khoảng 10,89 phút nếu giả định giây đúng, trong khi trung bình tương đương hơn 14 giờ. Sự tương phản này giúp nhận biết vấn đề thang phân phối; không dùng trung bình đó để mô tả thời lượng điển hình của một trận. Metadata `eda_scope.json` xác nhận không dùng test, không loại ngoại lệ và không áp dụng biến đổi log trong lần chạy.



scope=full/train+validation; nguồn=hist_player_survive_time_source.csv; N bảng vẽ=30. 30 khoảng min-max train+validation, kể cả khoảng0; trụcX=biên trái, right_edge/source_unit ở bảng. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N quan sát trong bảng: 0..57262810. N population=57262855.

Hình 1: Phân phối thời gian sống trong EDA

Nhận xét: Khoảng trục rất rộng phản ánh các giá trị cực đoan. Phần lớn dữ liệu bị dồn về vùng thấp; không diễn giải chiều cao cột như bằng chứng dữ liệu có thang đo đồng nhất.



scope=full/stage scope; nguồn=eda_missing_source.csv; N bảng vẽ=21. Missing khác zero; N/valid/missing trong bảng nguồn. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N quan sát trong bảng: 57262855..57262855.

Hình 2: Giá trị thiếu theo đặc trưng

Nhận xét: Các tỷ số và thời điểm giao tranh có thiếu mang tính cấu trúc. Cần đọc định nghĩa mẫu số trước khi quyết định điền thiếu.

2.5 Chia tập và chống rò rỉ dữ liệu

Tất cả dòng thuộc cùng một trận được đưa vào cùng một tập. Số trận trong train, validation và test lần lượt là 510.979, 109.495 và 109.495; tổng cộng 729.969 trận. Tỷ lệ xấp xỉ 70/15/15. Khoảng thời gian của ba tập chồng lấn trong bảng kết quả, vì vậy không diễn giải phép đánh giá này như dự báo các trận tương lai theo thời gian.

Manifest `split.json` ghi Grade C: chia ngẫu nhiên có seed theo nhóm trận, do chưa thiết lập được ngữ nghĩa chronology đủ tin cậy; số giao nhau giữa các tập theo match bằng 0. Chia theo trận hạn chế việc các đồng đội hoặc đối thủ của cùng trận xuất hiện ở cả train và test. Cách chia này chưa bảo đảm một người chơi chỉ xuất hiện ở một tập, nên khả năng khái quát sang người chơi hoàn toàn mới vẫn là câu hỏi mở.

Bảng 3: Cohort train/validation; T0 và P2 trùng cohort hash

Bài toán	Tập	Dòng	Trận
s1	train	47158595	510979
s1	validation	10104260	109495
p2	train	47068529	509375
p2	validation	10084731	109143
t0	train	47068529	509375
t0	validation	10084731	109143

Nguồn: `model_cohorts.csv`, số liệu đầy đủ đã lưu.

Hash cohort của T0 và P2 trùng nhau trên cả train và validation, theo `model_cohorts.csv`. Số dòng test là 10.106.376 cho survival và 10.085.842 cho placement, theo `model_metrics.csv`. Các số lượng được báo theo từng bài toán, không ép bằng nhau bằng cách bỏ thêm dữ liệu.

Các tham số điền thiếu, chuẩn hóa và hồi quy được học từ tập huấn luyện. Tập validation phục vụ kiểm tra và quyết định trước khi mở test. Quan hệ phục vụ phát triển được tính trên train và validation. Các đặc trưng chứa trực tiếp thời gian sống hoặc có mẫu số phụ thuộc mục tiêu không được dùng để dự đoán thời gian sống. Việc đã quan sát test trong lịch sử dự án là giới hạn cần lưu ý khi mở thêm thí nghiệm.

2.6 Xây dựng Combat Timing

Thời gian trận được xấp xỉ bằng giá trị thời gian sống lớn nhất trong trận. Sự kiện được chia thành ba pha theo tỷ lệ thời điểm so với thời lượng xấp xỉ: đầu trận $[0, 1/3)$, giữa trận $[1/3, 2/3)$ và cuối trận $[2/3, 1]$. Đây là quy ước khai phá, không phải thời lượng chính thức từ máy chủ.

Cần phân biệt người chơi được xác nhận không có lần hạ gục với người có số kill trong aggregate nhưng thiếu sự kiện tương ứng. Trường hợp thứ hai phản ánh độ bao phủ dữ liệu, không thể thay bằng không giao tranh. Những sự kiện có timing tuyệt đối hợp lệ nhưng pha không hợp lệ được giữ trạng thái riêng. Các tỷ lệ pha chỉ sử dụng mẫu số pha hợp lệ.

Timing theo pha phụ thuộc gián tiếp vào thời gian sống qua mẫu số xấp xỉ. Vì vậy, nhóm loại nhóm biến này khỏi hồi quy survival nhưng công bố sự phụ thuộc khi sử dụng trong placement. Event được ghi nhận theo killer, loại tự hạ gục và kiểm match/time; thiết kế chưa bảo đảm tất cả sự kiện đều là hạ gục đối phương khác đội.

Bảng 4: Độ bao phủ timing trên 67.369.231 dòng

Trạng thái	Số dòng	Tỷ lệ (%)
absolute_only	21688	0.0321927
confirmed_no_kill	38766708	57.5436
event_missing	473147	0.702319
phase_observed	28107688	41.7218

Nguồn: `coverage_summary.csv`*, số liệu đầy đủ đã lưu.*

Trong 67.369.231 dòng, có 38.766.708 trường hợp confirmed_no_kill, 28.107.688 phase_observed, 473.147 event_missing và 21.688 absolute_only. Bốn nhóm cộng đúng tổng đầu vào. Gần 57,54% dòng được xác nhận không có kill, nên thiếu thời điểm giao tranh ở những dòng này có ý nghĩa cấu trúc. Khoảng 0,70% dòng thiếu event tương ứng cần được phân biệt với việc không giao tranh. Trạng thái phase_observed là trạng thái trên dòng người chơi, còn absolute_eligible/phase_eligible trong audit đếm sự kiện; không so trực tiếp hai đơn vị này.

2.7 Đặc trưng và quyền sử dụng theo mục tiêu

Bảng 5: Allowlist đầu vào từ registry

Đặc trưng	S1	P2/T1	T0
player_kills	True	True	True
player_dmg	True	True	True
player_dist_walk	True	True	True
player_dist_ride	True	True	True
player_assists	True	True	True
player_dbno	True	True	True
damage_per_kill	True	True	True
total_distance	True	True	True
walk_ratio	True	True	True
assist_ratio	True	True	True
first_kill_time	True	True	False
avg_kill_time	True	True	False
has_kill	True	True	False
early_kills	False	True	False
early_kill_ratio	False	True	False
mid_kills	False	True	False
mid_kill_ratio	False	True	False
late_kills	False	True	False
late_kill_ratio	False	True	False

Nguồn: `feature_dictionary.csv`*, số liệu đầy đủ đã lưu.*

Ký hiệu True trong bảng cho biết đặc trưng được phép dùng ở nhánh tương ứng, trước bước bổ sung chỉ báo thiếu. Ba nhánh cùng có 10 đặc trưng hành vi cơ sở; S1 bổ sung timing tuyệt đối và has_kill, P2 bổ sung cả timing theo pha, còn T0 bỏ toàn nhóm timing. Mục tiêu, thời lượng xấp xỉ và các biến như kills_per_minute không được đưa vào allowlist chính của các nhánh này.

Ví dụ, $damage_per_kill = damage/kills$ chỉ có nghĩa khi $kills > 0$, còn $walk_ratio = walk/(walk + ride)$ cần tổng khoảng cách dương. Các điều kiện này giải thích tại sao cùng một cohort nhưng số quan sát hợp lệ theo từng đặc trưng khác nhau. Bộ tiền xử lý học cách điền thiếu và thang chuẩn hóa từ train, đồng thời giữ chỉ báo thiếu để biểu diễn thông tin về tình trạng quan sát.

3 CÁC PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU

3.1 Tương quan Pearson và Spearman

Pearson đo liên hệ tuyến tính giữa hai biến; Spearman đo liên hệ đơn điệu thông qua thứ hạng. Với các biến có phân phối lệch và ngoại lệ lớn, hai hệ số có thể khác nhau rõ rệt. Nhóm báo cả hai thay vì chọn hệ số thuận lợi hơn cho kết luận:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

Spearman được tính trên thứ hạng toàn phạm vi, có xử lý đồng hạng. Không lấy trung bình tương quan từng khối dữ liệu. Mỗi cặp biến có số quan sát hợp lệ riêng; các cặp có biến tỷ số hoặc timing thường có ít quan sát hơn các biến gốc.

3.2 Phân cụm KMeans theo chế độ chơi

KMeans tìm các tâm cụm để tối thiểu hóa tổng khoảng cách bình phương:

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \sum_{\boldsymbol{x}_i \in C_k} \|\boldsymbol{x}_i - \boldsymbol{\mu}_k\|_2^2.$$

Mục tiêu này giải thích vì sao chuẩn hóa đặc trưng và kiểm ngoại lệ có vai trò quan trọng khi diễn giải khoảng cách; tài liệu KMeans chính thức cũng mô tả phương pháp theo tổng bình phương trong cụm [6]. Nhóm xây dựng hồ sơ từ trung bình và độ lệch chuẩn của kills, damage cùng các đặc trưng di chuyển, hỗ trợ và timing. Số trận được dùng để lọc độ tin cậy, không làm đầu vào chính. Ngưỡng tối thiểu 10 trận là quy ước thiết kế; chưa được chứng minh tối ưu.

Mỗi chế độ Solo, Duo và Squad có mô hình riêng. Các biến được điền thiếu và chuẩn hóa trước khi tính khoảng cách. K được xét trong khoảng 2 đến 8, chọn theo silhouette development hữu hạn lớn nhất; trường hợp hòa chính xác ưu tiên K nhỏ hơn. Silhouette dùng mẫu chẩn đoán 2.000 hồ sơ với seed 42, trong khi quá trình fit dùng toàn bộ hồ sơ đủ điều kiện. Davies–Bouldin, tỷ trọng cụm nhỏ nhất và ARI qua seed được báo để đánh giá chất lượng bổ sung.

Silhouette cao chưa đủ chứng minh các cụm có ý nghĩa. Một nhóm rất nhỏ gồm điểm cực đoan có thể tách xa phần còn lại và làm chỉ số có vẻ tốt. Vì vậy, số lượng thành viên, tâm cụm và độ ổn định phải được đọc đồng thời. Tên mô tả cụm được đặt từ hành vi; kết quả sống sót và thứ hạng chỉ được đối chiếu sau khi khóa phân cụm.

Silhouette đánh giá tương quan giữa khoảng cách trong cụm và khoảng cách đến cụm lân cận, $s = (b - a)/\max(a, b)$. ARI đo mức nhất quán của hai phân hoạch sau hiệu chỉnh sự trùng khớp ngẫu nhiên; giá trị gần 1 thể hiện độ nhất quán cao hơn. Hai chỉ số trả lời hai câu hỏi khác nhau, do đó một cấu hình đạt silhouette cao vẫn có thể nhạy với seed [6].

3.3 Mô hình cơ sở và hồi quy tuyến tính

Mô hình mean dự đoán bằng trung bình mục tiêu trên train; mô hình median dự đoán bằng trung vị train. Hai mốc cơ sở giúp trả lời liệu việc đưa đặc trưng vào mô hình có tạo ra giá trị thực tế. Với mục tiêu có ngoại lệ, median thường phản ánh vị trí điển hình tốt hơn mean nhưng kết quả phải được kiểm bằng dữ liệu cụ thể.

Hồi quy tuyến tính có dạng $\hat{y}_i = \beta_0 + \boldsymbol{x}_i^T \boldsymbol{\beta}$ và tối thiểu hóa tổng bình phương phần dư. Đầu vào được chuẩn hóa bằng thống kê train. Do quy mô lớn, hệ thống dùng QR theo khối và SVD trên ma trận nhỏ để giải bài toán bình phương tối thiểu toàn cục. Mỗi khối tối đa 50.000 dòng; đây không phải huấn luyện các mô hình riêng rồi lấy trung bình hệ số.

Về mặt phương pháp, các đặc trưng phụ thuộc tuyến tính có thể làm hệ số khó diễn giải riêng lẻ. Đây là vấn đề đa cộng tuyến của hồi quy bình phương tối thiểu [7]. Trong bộ đặc trưng này, total_distance bằng tổng walk và ride, vì vậy cần thận trọng khi diễn giải riêng từng hệ số của ba cột.

Thiết kế có bảy lần fit logic: S1 mean, median, linear cho survival; P2 mean, median, linear cho placement; T0 linear cho placement không có timing. T1 dùng lại P2 linear. Hai nhánh T0/T1 được so sánh trên cùng row IDs, mục tiêu và split. Không sử dụng thuật toán học sâu trong bài chính.

3.4 Thước đo đánh giá

$$\text{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}, \quad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

MAE dễ đọc theo đơn vị mục tiêu; RMSE nhạy hơn với lỗi lớn. R^2 có thể âm và không phải accuracy. Với placement, ngoài micro theo dòng người chơi, nhóm tính match-aware với trọng số nghịch đảo số dòng của trận và team-aware theo đội. Không lấy trung bình RMSE hay R^2 của từng khối để thay cho kết quả toàn tập.

Mốc $R^2 = 0$ tương ứng với dự đoán bằng trung bình của chính tập đang đánh giá; baseline mean của dự án lại sử dụng trung bình train. Hai đại lượng không nhất thiết trùng nhau khi phân phối mục tiêu giữa các tập khác nhau. Vì vậy, baseline mean có thể có R^2 rất âm mà không mâu thuẫn với định nghĩa chỉ số [8].

4 THỬ NGHIỆM VÀ KẾT QUẢ

4.1 Thiết lập và nguồn bằng chứng

Kết quả được tổng hợp từ bốn notebook đã chạy: S00–S06, S07, S08 và S09–S12. Môi trường thể hiện Python 3.13.15, DuckDB 1.5.6, với các bước mô hình sử dụng GPU T4 theo cấu hình. SQL, thống kê và đánh giá chạy trên CPU. Bộ nhớ GPU không thay thế RAM của các thao tác SQL.

Bản hoàn thiện đọc trực tiếp 81 tệp CSV trong snapshot S09–S10, đối chiếu SHA256 với handoff trước khi chọn số liệu đưa vào báo cáo. Bộ nhập trước đó đã xác nhận 466 entry trong handoff, checkpoint S01–S10 và inventory của một release. Báo cáo đính kèm các CSV nguồn cần cho bảng trình bày cùng chỉ mục truy vết. Một bảng trình bày có thể chọn bớt cột hoặc nhóm để dễ đọc, nhưng không còn phụ thuộc giới hạn 20/25 dòng của notebook. Trạng thái completed xác nhận quy trình hoàn tất; hiệu năng vẫn phải được đánh giá độc lập bằng số liệu.

Các phiên bản phần mềm ghi trong kết quả gồm NumPy 2.1.3, pandas 2.3.3, PyArrow 23.0.1, scikit-learn 1.6.1 và cuML 26.02.000. Tài liệu trực tuyến được dẫn để giải thích phương pháp, không được dùng thay metadata phần mềm thực nghiệm. Cổng chọn mô hình ghi train-only, test chưa được truy cập tại thời điểm phê duyệt và không refit trên train+validation; lịch sử test exposure trước đó được ghi là unknown.

4.2 RQ1: Quan hệ giữa hành vi và kết quả

Bảng 6: Quan hệ với placement, train+validation, Overall

Đặc trưng	N	Pearson	Spearman
player_kills	5.71533e+07	0.372175	0.374387
player_dmg	5.71533e+07	0.395892	0.403764
player_dist_walk	5.71533e+07	0.224755	0.817044
player_dist_ride	5.71533e+07	0.508084	0.623494
total_distance	5.71533e+07	0.382926	0.805862
walk_ratio	5.58615e+07	-0.50189	-0.55535
avg_kill_time	2.38651e+07	0.707694	0.737909
early_kill_ratio	2.38467e+07	-0.635282	-0.64911
late_kill_ratio	2.38467e+07	0.539896	0.629308

Nguồn: `rq1_relationships.csv`, số liệu đầy đủ đã lưu.

Trên 57.262.855 quan sát hợp lệ ở các cặp biến gốc với survival, Spearman của quãng đường đi bộ đạt 0,909129, trong khi Pearson chỉ 0,001197. Với số kill, hai giá trị lần lượt là

0,400674 và -0,000438. Sự khác biệt lớn này phù hợp với cảnh báo về phân phối thời gian sống có giá trị cực đoan, nhưng riêng tương quan chưa xác định được nguyên nhân.

Đối với placement, Pearson của sát thương là 0,395892 và Spearman là 0,403764 trên 57.153.260 dòng. Đây là liên hệ quan sát có mức độ vừa, không đủ để khẳng định tăng sát thương sẽ làm tăng thứ hạng. Người sống lâu có nhiều thời gian tích lũy di chuyển và giao tranh; chiều tác động có thể đan xen.

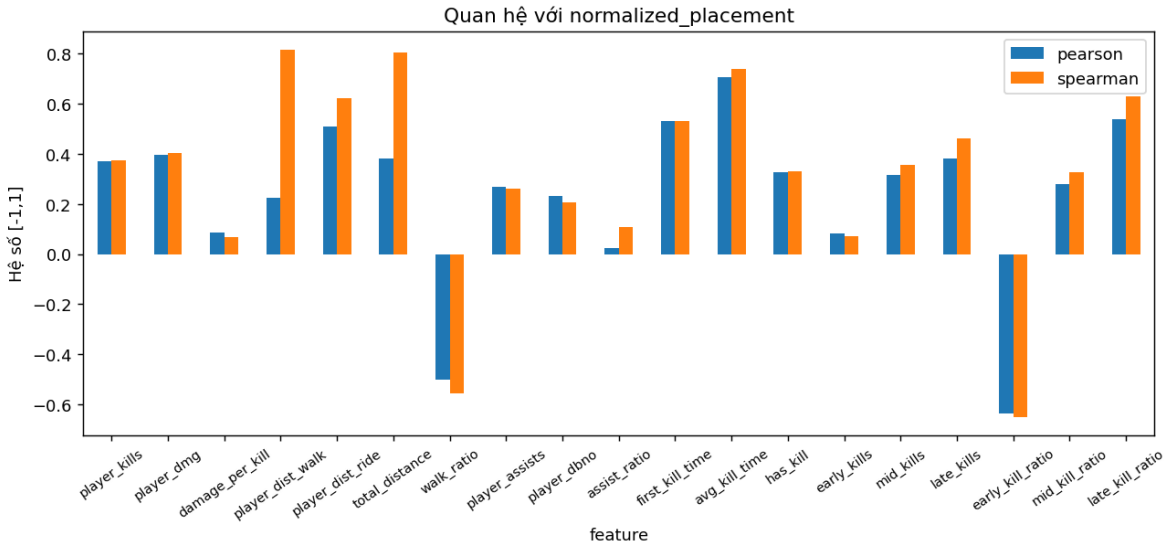
Bảng 7: Liên hệ giữa đi bộ và placement theo chế độ

Chế độ	N	Pearson	Spearman
Overall	5.71533e+07	0.224755	0.817044
Duo	1.8331e+07	0.228153	0.856024
Solo	1.18936e+07	0.184391	0.924975
Squad	2.69287e+07	0.254158	0.750895

Nguồn: `rq1_relationships.csv`, số liệu đầy đủ đã lưu.

Đi bộ có Spearman dương với placement trong cả ba chế độ, nhưng mức độ khác nhau: Solo khoảng 0,925, Duo 0,856 và Squad 0,751. Hướng liên hệ nhất quán không có nghĩa cùng một mức tăng khoảng cách dẫn tới cùng một mức tăng thứ hạng. Đối với timing, early_kill_ratio có Spearman -0,649110 còn late_kill_ratio có 0,629308 trong Overall; đây là mô tả trên các dòng có timing hợp lệ và còn chịu ảnh hưởng của thời lượng trận xấp xỉ.

Một chi tiết cần lưu ý là player_dbno ở Solo có tương quan không xác định, được nguồn ghi status=undefined. Trường hợp này phải giữ NA, không diễn giải thành tương quan bằng 0. Việc báo N hợp lệ của từng cặp cũng tránh so sánh trực tiếp hệ số tính trên 23,8 triệu dòng timing với hệ số tính trên hơn 57 triệu dòng biến gốc mà bỏ qua khác biệt độ bao phủ.



scope=full/train+validation; nguồn=rq1_normalized_placement_source.csv; N bảng vẽ=19. Hệ số giữ dấu; N từng cặp và primary flag trong bảng; không suy nhân quả. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N quan sát trong bảng: 23846748.0..57153260.0.

Hình 3: Quan hệ hành vi với thứ hạng chuẩn hóa

Nhận xét: Cần đọc dấu và độ lớn của cả Pearson và Spearman; sự liên hệ không chứng minh quan hệ nhân quả.

4.3 RQ2: Phân nhóm hành vi

Bảng 8: Hồ sơ development với ngưỡng ít nhất 10 trận

Chế độ	Tổng hồ sơ	Giữ lại	Tỷ lệ	Trung vị trận
Duo	3993459	446791	0.111881	16
Solo	3002934	269635	0.0897905	15
Squad	5085020	665206	0.130817	16

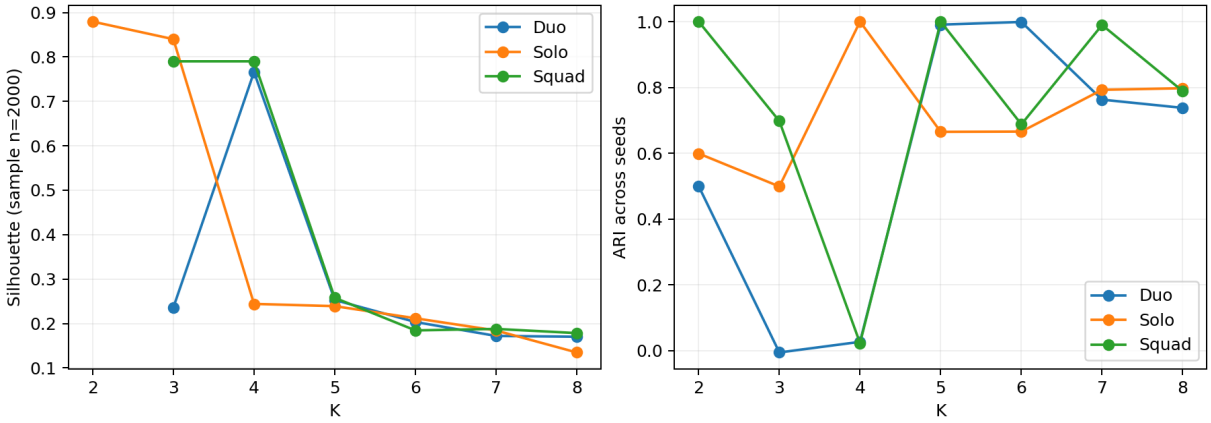
Nguồn: `profile_retention.csv`, *số liệu đầy đủ đã lưu.*

Ngưỡng ít nhất 10 trận giữ lại 446.791 hồ sơ Duo, 269.635 Solo và 665.206 Squad ở development, tương ứng khoảng 11,19%, 8,98% và 13,08% số hồ sơ cùng chế độ. Do vậy, kết luận phân cụm chủ yếu mô tả những hồ sơ có đủ lịch sử, không đại diện đồng đều cho người chỉ xuất hiện một vài trận. Khi chuyển sang full descriptive sau khóa lựa chọn, tổng số hồ sơ được gán cụm là 540.292 Duo, 327.422 Solo và 800.422 Squad. Hai bộ số lượng thuộc hai phạm vi khác nhau.

Bảng 9: Chẩn đoán development tại K đã chọn; mẫu silhouette 2.000

Chế độ	K	Hồ sơ	Silhouette	ARI	Tỷ trọng nhỏ nhất
Duo	4	446791	0.765926	0.0270453	8.95273e-06
Solo	2	269635	0.879534	0.599239	0.0052738
Squad	3	665206	0.790095	0.69783	2.25494e-05

Nguồn: `k_diagnostics.csv`, *số liệu đầy đủ đã lưu.*



Hình 4: Silhouette và độ ổn định theo K trên development

Nhận xét: Đường có giá trị thiếu được giữ khoảng trống. Quy tắc chọn K xét silhouette hữu hạn; ARI được báo để diễn giải độ ổn định. Nguồn: k_diagnostics.csv đầy đủ.

Bảng 10: Kích thước cụm của bản mô tả full

Chế độ	Cụm	Hồ sơ	Tỷ trọng
Duo	0	536336	0.992678
Duo	1	4	7.4034e-06
Duo	2	261	0.000483072
Duo	3	3691	0.00683149
Solo	0	86451	0.264035
Solo	1	240971	0.735965
Squad	0	6642	0.00829812
Squad	1	13	1.62414e-05
Squad	2	793767	0.991686

Nguồn: `cluster_sizes.csv`, *số liệu đầy đủ đã lưu.*

Kết quả cuối cùng có 4 cụm Duo, 2 cụm Solo và 3 cụm Squad. Solo phân chia tương đối rõ về mức độ giao tranh: cụm 0 có trung bình 1,627 kill và 190,983 sát thương mỗi trận; cụm

1 lần lượt là 0,617 và 83,189. Có thể mô tả hai nhóm là giao tranh cao hơn và giao tranh thấp hơn trong chính chế độ Solo, tránh quy chúng thành hai kiểu người chơi tuyệt đối.

Duo và Squad có phân bố rất lệch. Cụm Duo 0 chiếm khoảng 99,268%, còn cụm Duo 1 chỉ có 4 hồ sơ. Cụm Squad 2 chiếm khoảng 99,169%, trong khi cụm Squad 1 có 13 hồ sơ. Cụm Duo 2 có trung bình quãng đường đi bộ khoảng 36.375,383 theo đơn vị nguồn, cao hơn rõ rệt nhóm chính. Những kết quả này gợi ý cần xem xét sự chi phối của ngoại lệ và cấu trúc giá trị thiếu trước khi gắn nhãn phong cách chơi.

Trong chẩn đoán development, cấu hình Duo với K=4 có silhouette 0,765926 nhưng ARI qua seed chỉ 0,027045. Đây là ví dụ trực tiếp cho thấy độ tách biệt trên mẫu và độ ổn định nhãn không đồng nghĩa. Không nên công bố bộ cụm này như một hệ phân loại hành vi bền vững khi chưa có phân tích bổ sung.

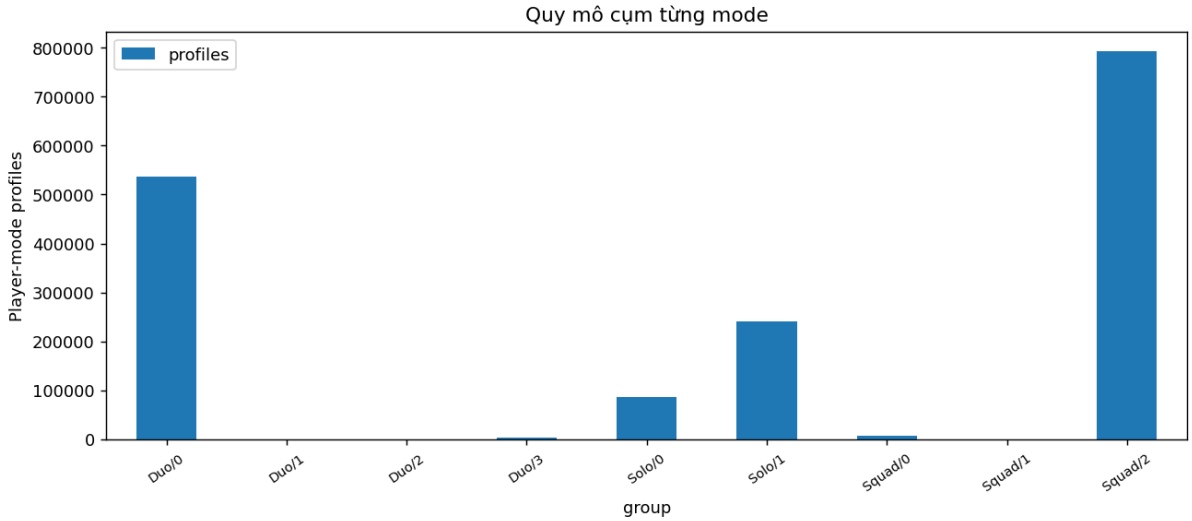
Bảng 11: Tâm cụm mô tả ở thang gốc

Chế độ	Cụm	Kill TB	Damage TB	Đi bộ TB	Hỗ trợ TB
Duo	0	0.912754	127.165	1202.03	0.226837
Duo	1	0	0	0	0
Duo	2	1.20096	158.919	36375.4	0.245311
Duo	3	0.00777386	27.0614	1081.16	0.098025
Solo	0	1.6273	190.983	1323.31	0.0930827
Solo	1	0.617178	83.1888	1083.43	0.0516452
Squad	0	0.00673101	27.5129	1194.72	0.126149
Squad	1	0	0	0	0
Squad	2	0.892359	130.926	1364.68	0.313916

Nguồn: `cluster_centers.csv`, số liệu đầy đủ đã lưu.

Với K đã chọn, Solo có ARI khoảng 0,599 và Squad khoảng 0,698, đều cao hơn Duo nhưng chưa đạt nhất quán hoàn toàn. Một số cấu hình K khác ổn định hơn nhưng không được chọn do quy tắc nghiên cứu đã đăng ký ưu tiên silhouette hữu hạn cao nhất. Báo cáo giữ lựa chọn đã chạy, đồng thời công bố hạn chế thay vì đổi K sau khi xem outcome.

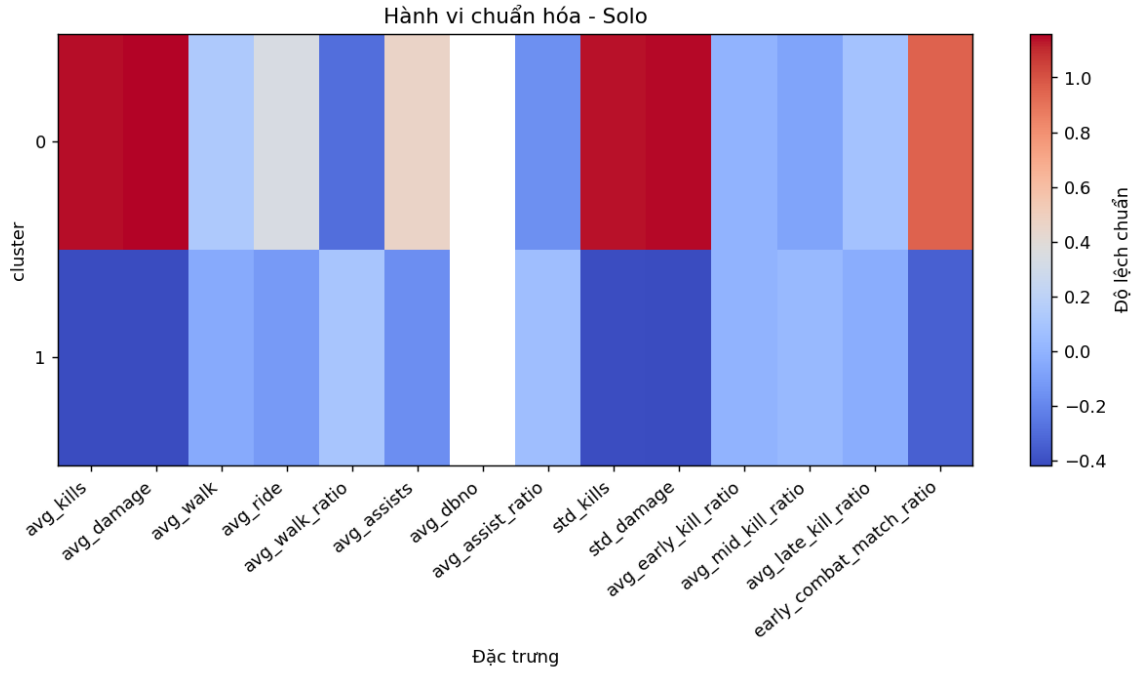
Tên mô tả phù hợp cho cụm Solo 0 là giao tranh tích cực hơn tương đối, còn Solo 1 là giao tranh thấp hơn tương đối. Cụm Duo 2 có mức di chuyển bất thường cần kiểm tra; các cụm Duo 1/Squad 1 có nhiều trung bình hành vi bằng 0 và quy mô rất nhỏ nên chưa đủ căn cứ gắn ý nghĩa chiến thuật. Số liệu mean survival trong cluster_outcomes cũng có giá trị rất lớn, nên không dùng bảng đó để kết luận nhóm nào sống lâu hơn theo nghĩa thực tiễn khi vấn đề nguồn chưa được giải thích.



scope=full/stage scope; nguồn=cluster_sizes_source.csv; N bảng vẽ=9. Mẫu số và share riêng từng mode. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn.

Hình 5: Phân bố kích thước cụm

Nhận xét: Duo và Squad tập trung vào một cụm lớn. Các cụm cực nhỏ cần được xem như đối tượng kiểm tra bổ sung.



scope=full/full descriptive; nguồn=centers_Solo_source.csv; N bảng vẽ=2. Màu thể hiện lệch so với profile mean, không xếp hạng tốt/xấu; cluster ID chỉ trong mode. Ô trắng là variance0/undefined. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N population=327422.

Hình 6: Đặc trưng tương đối của hai cụm Solo

Nhận xét: Các ô thể hiện thang tương đối trong hình nguồn; giá trị âm không có nghĩa số kill âm. Bảng tâm cụm ở thang gốc được dùng để mô tả hành vi.

4.4 RQ3: Kết quả hồi quy trên validation

Bảng 12: Validation theo micro; survival và placement khác đơn vị

Thí nghiệm	N	MAE	RMSE	R^2
s1_mean	10104260	60734.1	60736.8	-11115.5
s1_median	10104260	499.487	591.234	-0.0533772
p2_mean	10084731	0.262794	0.301826	-5.12551e-08
p2_median	10084731	0.262756	0.301891	-0.000432201
s1_linear	10104260	187007	351149	-371575
p2_linear	10084731	0.17349	0.21741	0.481143
t0_linear	10084731	0.186753	0.231319	0.41263

Nguồn: `model_metrics.csv`*, số liệu đầy đủ đã lưu.*

Với placement, hồi quy P2 đạt MAE 0,173490 và $R^2 = 0,481143$ trên validation, tốt hơn mốc mean có MAE 0,262794 và R^2 xấp xỉ 0. T0 chưa có timing đạt MAE 0,186753. Như vậy,

các đặc trưng hành vi cung cấp thông tin giải thích thứ hạng trong thiết kế hồi cứu này.

Ngược lại, S1 linear có MAE 187.006,670 và R^2 khoảng $-3,716 \times 10^5$ trên validation. Baseline median có MAE 499,487, thấp hơn rất nhiều. Baseline mean cũng kém với MAE 60.734,082. Sự thất bại đồng thời của mean và hồi quy là một dấu hiệu cần kiểm tra phân phối train, thang đo và tính nhất quán của chuỗi xử lý; không thể quy toàn bộ vấn đề cho thuật toán tuyến tính khi chưa đối soát sâu hơn.

4.5 Kết quả đầy đủ trên tập test

Bảng 13: Kết quả test survival theo micro

Thí nghiệm	N	MAE	RMSE	R^2
s1_mean	10106376	60733.9	60736.6	-11118.9
s1_median	10106376	499.51	591.197	-0.0535738
s1_linear	10106376	186899	356912	-383991

Nguồn: `model_metrics.csv`, số liệu đầy đủ đã lưu.

Trên 10.106.376 dòng test survival, median đạt MAE 499,509606 và RMSE 591,196793, trong khi hồi quy có MAE 186.899,052476 và RMSE 356.911,707793. Hồi quy chưa vượt được baseline trung vị; việc thêm nhiều đặc trưng không tự bảo đảm chất lượng. Theo bins_s1.json, ngưỡng lớn nhất của mục tiêu train là 63.648.215.000, xác nhận ít nhất một giá trị train có quy mô rất khác các giá trị điển hình. Đây là bằng chứng của phân phối bất thường, chưa xác định được lỗi bắt nguồn từ dữ liệu hay chuỗi xử lý.

Manifest selection xác nhận cả bảy thí nghiệm được giữ theo đăng ký trước sau kiểm finite prediction, reload và cohort; không đặt ngưỡng hiệu năng để loại một mô hình. Vì vậy, việc S1 được ghi completed và có dự đoán test không phải bằng chứng S1 đạt chất lượng triển khai.

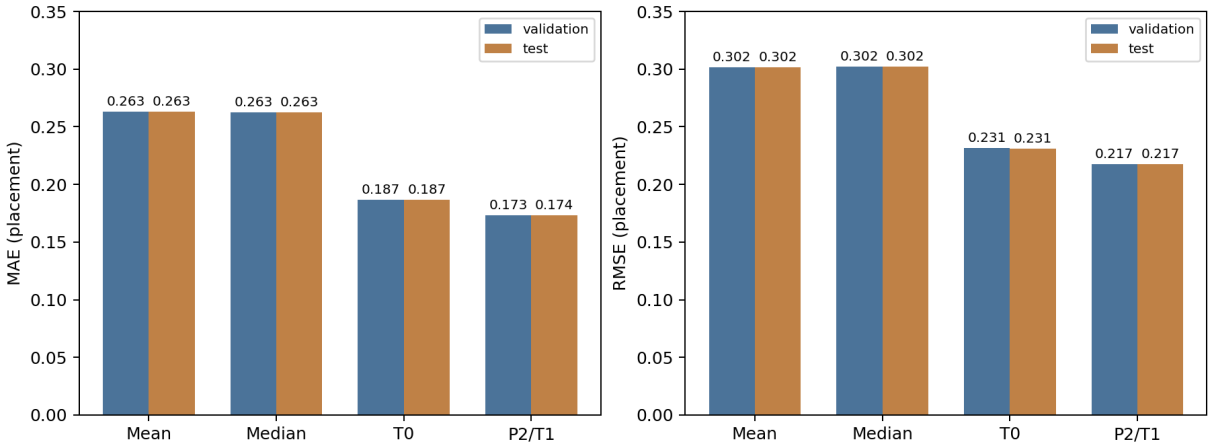
Bảng 14: Kết quả test placement theo micro

Thí nghiệm	N	MAE	RMSE	R^2
p2_mean	10085842	0.262813	0.301843	-3.00302e-08
p2_median	10085842	0.262774	0.301908	-0.000429946
p2_linear	10085842	0.173516	0.217318	0.481642
t0_linear	10085842	0.186802	0.23122	0.413202

Nguồn: `model_metrics.csv`, số liệu đầy đủ đã lưu.

Với placement, median có MAE 0,262774 còn P2 đạt 0,173516, giảm khoảng 33,97%. So với mean, mức giảm MAE cũng xấp xỉ 33,98%. Chênh lệch giữa MAE validation của P2

(0,173490) và test (0,173516) chỉ khoảng 0,000026, cho thấy hiệu năng nhất quán giữa hai tập trong cùng phép chia theo trận. Đây chưa phải kiểm định khái quát sang thời kỳ khác hoặc người chơi mới.



Hình 7: So sánh baseline, T0 và P2 giữa validation và test

Nhận xét: Hai panel dùng các chỉ số riêng biệt trên cùng mục tiêu placement. Các cột validation và test gần nhau; P2 có sai số thấp nhất trong bốn nhánh placement đã chạy. Nguồn: model_metrics.csv đầy đủ.

4.6 Đóng góp của Combat Timing trên test

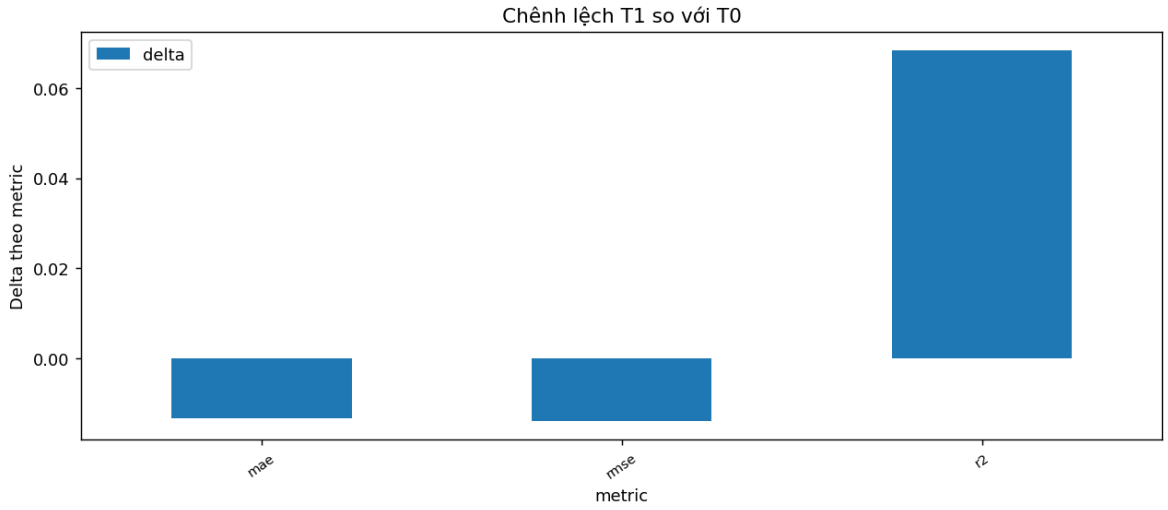
Bảng 15: Timing trên cùng cohort test; delta = T1 - T0

Cách tính	Metric	T0	T1	Chênh lệch	N
micro	mae	0.186802	0.173516	-0.0132862	10085842
micro	rmse	0.23122	0.217318	-0.0139018	10085842
micro	r2	0.413202	0.481642	0.0684399	10085842
match_aware	mae	0.186962	0.173608	-0.0133548	10085842
match_aware	rmse	0.23147	0.217483	-0.0139868	10085842
match_aware	r2	0.412739	0.481567	0.0688274	10085842
team_aware	mae	0.176237	0.160499	-0.0157383	5118612
team_aware	rmse	0.216231	0.198686	-0.0175453	5118612
team_aware	r2	0.486572	0.566512	0.0799401	5118612

Nguồn: `timing_comparison.csv`, *số liệu đầy đủ đã lưu.*

Trên cùng 10.085.842 dòng test, T1=P2 giảm MAE từ 0,186802 xuống 0,173516, tương đương khoảng 7,11% so với T0. RMSE giảm từ 0,231220 xuống 0,217318, khoảng 6,01%. R^2 tăng từ 0,413202 lên 0,481642, tức tăng 0,068440 điểm. Match-aware và team-aware cùng cho hướng cải thiện.

Các con số trên mô tả chênh lệch thực nghiệm của đúng cohort đã chạy. Cấu hình bootstrap_replicates bằng 0, nên chưa có khoảng tin cậy bootstrap và chưa có cơ sở tuyên bố ý nghĩa thống kê. Do timing pha chứa thông tin từ proxy thời lượng hậu trận, kết quả cũng không chứng minh khả năng dự báo trước trận hay tác động nhân quả của việc giao tranh sớm/muộn.



scope=full/test; nguồn=timing_delta_source.csv; N bảng vẽ=3. MAE/RMSE âm và R² dương là tốt hơn; không significance nếu CI chưa tính. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N quan sát trong bảng: 10085842..10085842.

Hình 8: Chênh lệch đánh giá khi bổ sung timing

Nhận xét: MAE và RMSE giảm, trong khi hệ số xác định tăng. Chưa có khoảng tin cậy để kết luận ý nghĩa thống kê.

4.7 Phân tích sai số

Bảng 16: Sai số test theo chế độ

Thí nghiệm	Nhóm	N	MAE	RMSE	R^2
s1_linear	Duo	3229814	183739	375817	-432669
s1_linear	Solo	2110622	178441	353394	-404335
s1_linear	Squad	4765940	192786	345115	-348685
p2_linear	Duo	3220788	0.165859	0.208053	0.519369
p2_linear	Solo	2104567	0.158561	0.200848	0.5428
p2_linear	Squad	4760487	0.185307	0.230084	0.430945

Nguồn: `error_analysis.csv`*, số liệu đầy đủ đã lưu.*

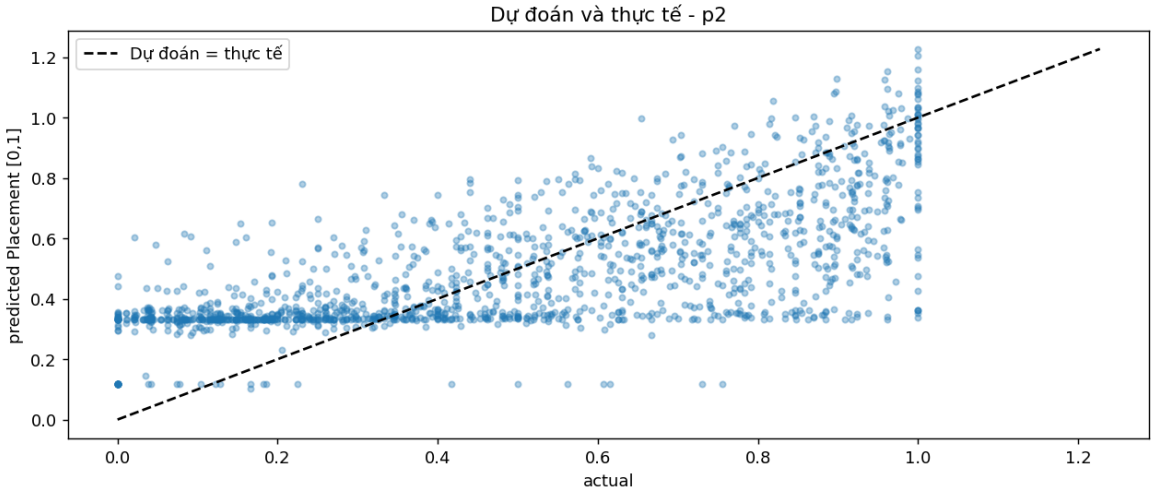
Với placement, Squad có MAE 0,185307, cao hơn Duo (0,165859) và Solo (0,158561); mức chênh Squad so với Solo khoảng 16,9%. So sánh này mô tả sự không đồng đều giữa các chế độ, chưa chứng minh khác biệt thống kê. Số quan sát và số trận cũng khác nhau, trong đó Squad chiếm gần một nửa dòng test placement.

Bảng 17: Sai số placement theo miền mục tiêu, ngưỡng từ train

Miền placement	N	MAE	RMSE	R^2
(-inf, 0.308]	3338791	0.199023	0.222717	-4.46935
(0.308, 0.675]	3418514	0.109781	0.147639	-0.942396
(0.675, inf]	3328537	0.213388	0.266387	-6.47754

Nguồn: `error_analysis.csv`, số liệu đầy đủ đã lưu.

Ba miền mục tiêu được xác định từ phân vị train, với mốc khoảng 0,307692 và 0,675325. Nhóm thứ hạng giữa có MAE 0,109781, thấp hơn nhóm dưới (0,199023) và nhóm trên (0,213388). Mô hình vì vậy dự đoán khó hơn ở hai đầu thang thứ hạng. Các giá trị R^2 âm theo miền không mâu thuẫn với R^2 dương toàn tập: mỗi miền có trung bình và phương sai mục tiêu riêng, thường nhỏ hơn phạm vi toàn tập. Không cộng số trận của ba miền vì một trận có thể đóng góp người chơi vào nhiều miền.

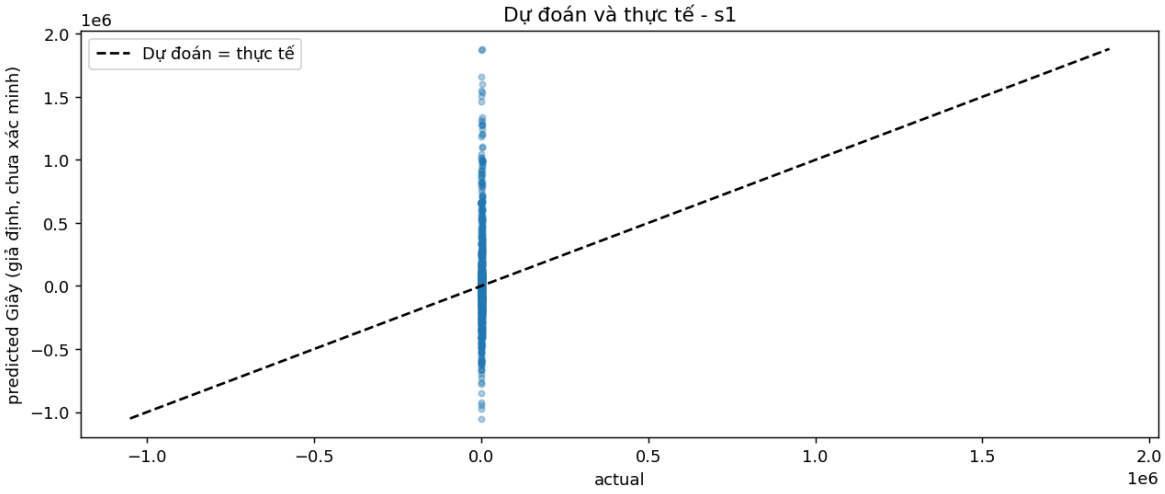


scope=full/test; nguồn=predicted_observed_p2_source.csv; N bảng vẽ=1500. Đường nét đứt là predicted=actual; sample chỉ vẽ, metrics trên toàn test cohort. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N population=10085842. visualization sample n=1500, seed=42, rule=uniform without replacement

Hình 9: Dự đoán và thực tế của placement

Nhận xét: Các điểm còn phân tán quanh đường chuẩn; mô hình có thông tin giải thích nhưng

chưa dự đoán chính xác từng trường hợp.



scope=full/test; nguồn=predicted_observed_s1_source.csv; N bảng vẽ=1500. Đường nét đứt là predicted=actual; sample chỉ vẽ, metrics trên toàn test cohort. Thời gian: giả định giây, chưa xác minh từ tác giả nguồn. N population=10106376. visualization sample n=1500, seed=42, rule=uniform without replacement

Hình 10: Dự đoán và thực tế của survival

Nhận xét: Thang dự đoán lệch rất xa thang thực tế ở nhiều điểm, có cả dự đoán âm. Kết quả này chưa phù hợp để sử dụng dự đoán thời gian sống.

Đường dự đoán bằng thực tế là mốc trực quan để xem mức độ lệch. Hình scatter chỉ lấy mẫu để trình bày; các metric được tính trên toàn bộ cohort hợp lệ. Vì vậy, không suy ra số lượng ngoại lệ toàn tập chỉ từ mật độ điểm trên hình.

4.8 Hệ số mô hình và khả năng diễn giải

Bảng 18: Một số hệ số P2, không phải tác động nhân quả

Đặc trưng P2	Hệ số chuẩn hóa
player_dmg	0.0640772
walk_ratio	-0.0783626
player_dbno	-0.034019
first_kill_time	-0.0563628
avg_kill_time	0.163657
late_kills	-0.0331908
late_kill_ratio	-0.0107033

Nguồn: `coefficients.csv`, số liệu đầy đủ đã lưu.

Hệ số của avg_kill_time trong P2 là 0,163657, còn first_kill_time là -0,056363 trên thang đầu vào đã chuẩn hóa. Hai dấu khác nhau cho thấy hệ số riêng phần khi các biến khác cùng có trong mô hình có thể khác tương quan hai biến đơn lẻ. Hệ số âm của late_kill_ratio cũng không phủ định Spearman dương quan sát được trước đó.

Các quan hệ phụ thuộc như total_distance=walk+ride, các tỷ lệ pha có tổng bằng 1 trên dòng hợp lệ và các chỉ báo thiếu liên quan khiến nhiều cột không độc lập. Do đó, bảng hệ số chỉ mô tả nghiệm của recipe đã chạy, không phải bảng xếp hạng tầm quan trọng ổn định hay tác động nhân quả. Muốn đánh giá đóng góp riêng từng biến cần thí nghiệm bổ sung được thiết kế trước; phép T0/T1 hiện chỉ đánh giá cả nhóm timing.

5 THẢO LUẬN KẾT QUẢ

5.1 Vai trò của chất lượng dữ liệu

Kết quả nổi bật nhất về mặt phương pháp là sự khác biệt giữa hợp lệ theo kiểu dữ liệu và hợp lý về mặt nội dung. Một số thời gian sống rất lớn vẫn hữu hạn và không âm, nên vượt qua quy tắc hợp lệ ban đầu. Điều này giải thích vì sao sổ loại dòng bằng 0 không mâu thuẫn với việc EDA phát hiện phân phối bất thường. Bước tiếp theo cần đối chiếu bản ghi nguồn và quy tắc ngữ nghĩa trước khi xây dựng phiên bản làm sạch mới.

Không tự quy đổi toàn bộ thời gian theo một hệ số chỉ vì metric lớn. Nếu có nhiều nhóm đơn vị hoặc một số bản ghi lỗi, một phép đổi đơn vị đồng loạt có thể làm sai phần dữ liệu vốn hợp lý. Các giả thuyết cần được kiểm bằng lineage, thống kê theo shard, theo split và bản ghi nguồn cụ thể.

5.2 Giá trị và giới hạn của phân cụm

Solo tạo ra hai nhóm có khác biệt về mức độ giao tranh và quy mô đủ lớn để mô tả. Duo và Squad cho thấy các cụm cực nhỏ và một cụm chi phối gần như toàn bộ hồ sơ. Về ứng dụng, đây là tín hiệu chẩn đoán dữ liệu và không gian đặc trưng hơn là bằng chứng chắc chắn về các phong cách chiến thuật riêng biệt.

Việc đặt tên như "người chơi giỏi", "người chơi yếu" hoặc "gian lận" không được bảo đảm từ KMeans. Outcome có thể hỗ trợ diễn giải sau khóa, nhưng không biến một phân cụm không giám sát thành bộ phân loại năng lực hoặc phát hiện gian lận đã được kiểm định.

5.3 Diễn giải hiệu năng hồi quy

Placement cho kết quả nhất quán hơn survival trong bằng chứng hiện có. T0/T1 cùng cohort giúp giảm một nguồn sai lệch khi so sánh các nhóm đặc trưng. Tuy nhiên, mức tăng R^2 là kết quả của một thiết kế và bộ dữ liệu cụ thể; không thể khái quát thành kết luận timing luôn cải thiện mọi mô hình hoặc mọi mùa giải.

Đối với survival, baseline median là mốc thực nghiệm quan trọng vì cho sai số nhỏ hơn rõ rệt trong bảng hiển thị. Báo cáo chưa lựa chọn một mô hình survival để triển khai. Cần ưu tiên kiểm tra nguồn và kiểm định số học trước khi đề xuất thuật toán phức tạp hơn. Việc thêm mô hình mạnh hơn có thể che triệu chứng mà chưa giải quyết nguyên nhân.

5.4 Hạn chế và hướng phát triển

Các giới hạn chính gồm đơn vị thời gian chưa được xác minh độc lập; ngoại lệ survival rất lớn; sự phụ thuộc giữa các người chơi cùng trận và cùng đội; tên người chơi có thể không ổn định; timing phụ thuộc proxy hậu trận; độ bao phủ event khác aggregate; và chưa có khoảng tin cậy cho so sánh T0/T1. Bản hoàn thiện đã có CSV và snapshot đầy đủ để truy vết, nhưng chưa kiểm tra lại raw nguồn hoặc thực hiện thí nghiệm xác định nguyên nhân các bất thường.

Hướng phát triển phù hợp là đối soát dữ liệu theo shard và theo split, kiểm tra tác động của quy tắc chất lượng được đăng ký trước, đánh giá lại độ ổn định cụm và thực hiện bootstrap theo trận. Nếu mở rộng sang mô hình phi tuyến, cần giữ cùng cohort và thiết kế đánh giá để so sánh công bằng. Mọi thay đổi phải có phiên bản kết quả riêng; không dùng test hiện có để chỉnh rồi báo lại như kiểm định độc lập.

6 TỔ CHỨC HỆ THỐNG VÀ KHẢ NĂNG TÁI LẬP

6.1 Quy trình thực thi S01–S12

Các bước được tổ chức theo chuỗi: S01 kiểm nguồn; S02 làm sạch và chia tập; S03 tạo đặc trưng cơ sở; S04 tổng hợp timing; S05 EDA; S06 quan hệ; S07 phân cụm; S08 hồi quy; S09 so sánh và sai số; S10 khóa kết quả. S11 đọc báo cáo đã khóa và S12 tổng hợp thông tin bàn giao.

S10 không huấn luyện lại mô hình. Bước này kiểm tra phụ thuộc và các bảng bắt buộc, sao chụp kết quả được chọn, tạo manifest và con trỏ đến release. Do đó, số artifact riêng của S10 nhỏ không có nghĩa toàn dự án thiếu kết quả. Bằng chứng notebook cuối cho thấy S01–S10 đều completed và báo cáo S11 đã được hiển thị.

6.2 Xử lý dữ liệu vượt bộ nhớ

Dữ liệu được lưu dưới dạng Parquet và xử lý bằng SQL trên đĩa. Các thao tác ghép và sắp xếp lớn được tách pha để tránh đồng thời giữ nhiều cấu trúc trong RAM. Hồi quy dùng ma trận số dạng ánh xạ bộ nhớ, dự đoán theo lô và tổng hợp metric toàn cục. Hai GPU thực hiện các công việc độc lập; VRAM không được cộng thành một vùng nhớ chung.

Đây là lựa chọn tổ chức thực thi nhằm bảo toàn phạm vi dữ liệu. Việc chia khối không cho phép thay trung vị toàn train bằng trung bình trung vị các khối, cũng không cho phép thay RMSE toàn tập bằng trung bình RMSE từng lô. Mỗi bước phải giữ đúng đại lượng toán học cần tính.

6.3 Bàn giao và truy vết

Mỗi phiên tiếp tục khôi phục từ kết quả đã lưu, kiểm checksum và thông tin môi trường rồi chạy phần tiếp theo. Bộ notebook người dùng cung cấp phản ánh chuỗi S00–S06, S07, S08 và S09–S12. Báo cáo kèm một bảng ánh xạ nguồn để xác định mỗi bảng, hình đã trích từ notebook và output nào.

Snapshot đầy đủ nằm tại results/PUBG_Coursework_v511_S09_S10; con trỏ final_results.json dẫn tới release có mã `ff9f409dc0bc4720904d58545d25d1b4`. Bản cập nhật báo cáo sử dụng CSV đầy đủ và giữ nguyên code/config/model/prediction/checkpoint của snapshot. Công cụ dựng bảng chỉ đọc kết quả, không huấn luyện lại. Điều này giúp phân biệt việc hoàn thiện trình bày với một đợt thí nghiệm mới.

Sản phẩm thực hành của nhóm là notebook phân tích và trình đọc báo cáo. Khi bảo vệ, mở release đã lưu để đối chiếu bảng/hình, không cần chạy lại dữ liệu lớn. Phiên bản hiện tại chưa triển khai website hoặc dịch vụ dự đoán trực tuyến.

7 KẾT LUẬN

Đề tài đã xây dựng quy trình khai phá dữ liệu PUBG từ kiểm nguồn, tạo đặc trưng và khám phá quan hệ đến phân cụm, hồi quy và phân tích sai số. Bằng chứng thực thi có 67.369.231 dòng aggregate và 65.370.475 dòng event đầu vào, với phạm vi toàn bộ dữ liệu hợp lệ theo từng bài toán.

Đối với RQ1, các hệ số cho thấy liên hệ giữa hành vi và kết quả nhưng đồng thời bộc lộ tác động của phân phối lệch. Đối với RQ2, Solo có hai nhóm khác biệt về mức độ giao tranh; Duo và Squad cần thận trọng vì phân bố cụm mất cân đối và độ ổn định chưa đồng đều. Đối với RQ3, mô hình placement có giá trị giải thích và timing giúp giảm sai số trên cohort test đã chạy; mô hình survival chưa đạt chất lượng sử dụng.

Qua quá trình thực hiện, nhóm nhận thấy đóng góp của khai phá dữ liệu không chỉ nằm ở việc chạy thành công thuật toán. Khả năng nhận biết giới hạn, kiểm tra tính hợp lý của dữ liệu và trình bày trung thực kết quả là điều kiện để các mẫu tìm được có ý nghĩa. Báo cáo vì vậy giữ cả kết quả tích cực và các bất thường cần tiếp tục điều tra.

TÀI LIỆU THAM KHẢO

[1] Nhóm dự án. Thông tin nguồn PUBG Match Deaths and Statistics, Version 3, ghi trong cấu hình và source inventory của notebook thực nghiệm. Kaggle: `https://www.kaggle.com/datasets/skihikingkevin/pubg-match-deaths`.

[2] Nhóm 3. *PUBG Research Spec*, thiết kế 5.11 và các cập nhật thực thi đến ngày 22/10/2026. Tài liệu nội bộ dự án.

[3] Nhóm 3. *PUBG Implementation Plan*. Tài liệu triển khai và kiểm thử nội bộ dự án.

[4] Nhóm 3. Bộ kết quả thực nghiệm: `pubg_S00_S06.ipynb`, `pubg_S07.ipynb`, `pubg_S08.ipynb`, `pubg_S09_S10_S11_S12.ipynb`. Bản người dùng cung cấp ngày 23/10/2026.

[5] Nhóm 3. Snapshot kết quả `PUBG_Coursework_v511_S09_S10`, gói results.zip, hand-off S01–S10 và release ff9f409dc0bc4720904d58545d25d1b4. Đối chiếu local ngày 23/10/2026.

[6] Scikit-learn. *Clustering: K-means and clustering evaluation*. `https://scikit-learn.org/stable/modules/clustering.html`. Truy cập ngày 23/10/2026.

[7] Scikit-learn. *Linear Models: Ordinary Least Squares*. `https://scikit-learn.org/stable/modules/linear_model.html`. Truy cập ngày 23/10/2026.

[8] Scikit-learn. *Metrics and scoring: Regression metrics*. `https://scikit-learn.org/stable/modules/model_evaluation.html`. Truy cập ngày 23/10/2026.

A NGUỒN BẰNG CHỨNG VÀ PHẠM VI BẢNG TRÍCH

Các bảng của bản hoàn thiện được tạo từ CSV đầy đủ, giữ bản nguồn tại `evidence/full_results`. Công cụ build_full_results.py đọc 81 CSV, kiểm SHA256 với handoff và ghi số dòng của từng bảng vào verification.json. Bảng lớn cluster_assignments chỉ được đọc kiểm kê, không đóng kèm tên người chơi vào gói báo cáo. Các manifest về split, scope, chọn cụm, chọn mô hình, bins và uncertainty cũng được lưu để đối chiếu. coverage_summary là bảng dẫn xuất bằng tổng số dòng theo trạng thái, được ghi nguồn rõ trong chỉ mục.

Các hình cũ được trích nguyên PNG từ notebook và còn ánh xạ tại evidence/index.json; hai hình mới được vẽ trực tiếp từ model_metrics.csv và k_diagnostics.csv. Tệp SOURCE_MAP.md liệt kê bảng/hình cập nhật. Các bảng xem trước lịch sử vẫn được giữ để đối chiếu, không dùng thay nguồn đầy đủ trong bản báo cáo này.

Phạm vi kiểm tra của đợt báo cáo là số liệu đã lưu, checksum, manifest và sự nhất quán khi trình bày. Không thực thi notebook nguồn, không nạp joblib, không sửa nhãn hoặc dữ liệu và không tính lại dự đoán. Các bất thường survival và hạn chế ổn định cụm vì vậy vẫn được trình bày như kết quả quan sát cần điều tra, thay vì tự thay đổi pipeline để làm đẹp báo cáo.

Danh sách thành viên, email và bố cục bìa dựa trên báo cáo môn Học máy do người dùng cung cấp. Giảng viên hướng dẫn môn Khai phá dữ liệu là ThS. Phạm Kim Thành theo thông tin người dùng xác nhận.